Repaso de conocimientos previos

Teoría de la Información

Prof. Víctor Adrián Sosa Hernández

Tabla de contenidos

1 Probabilidad de eventos 1
2 Logaritmos 2
3 Variables aleatorias discretas y valor esperado 2
4 Distribuciones conjuntas, marginales y condicionales 3
5 Funciones convexas 3
6 Cadenas de Markov 4
7 Búsqueda binaria y $\log_2 n$ 4
8 ¿Qué es "información"? 5

Este documento reúne los temas que el curso da por conocidos. Cada sección tiene un resumen breve, las fórmulas que se usan (numeradas, con cada parte explicada) y un ejercicio resuelto paso a paso. No es un examen: es material para repasar a su propio ritmo.

1 Probabilidad de eventos

Qué se debe saber. Un *experimento aleatorio* tiene un conjunto de resultados posibles; un *evento* A es un subconjunto de esos resultados y $P(A)$ es su probabilidad, un número entre 0 y 1.

$$P(A^c) = 1 - P(A) \tag{1}$$

Parte	Qué significa
A^c	el **complemento** de A: "no ocurre A"
$P(A^c)$	probabilidad de que A no ocurra

$$P(A \cap B) = P(A)\,P(B) \quad \text{si} \quad A \quad \text{y} \quad B \quad \text{son independientes} \tag{2}$$

Parte	Qué significa
$A \cap B$	ocurren A **y** B
independientes	saber que ocurrió uno no cambia la probabilidad del otro

Ejercicio resuelto. Se lanza una moneda justa 3 veces. ¿Cuál es la probabilidad de obtener al menos una cara?

1. "Al menos una cara" tiene muchos casos (1, 2 o 3 caras). Su complemento tiene uno solo: **ninguna cara** (3 cruces).
2. Los lanzamientos son independientes, así que por la Ecuación 2: $P(3 \text{ cruces}) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}$.
3. Por la Ecuación 1: $P(\text{al menos una cara}) = 1 - \frac{1}{8} = \frac{7}{8}$.

Conexión con el curso: la información de un evento depende sólo de su probabilidad; eventos independientes suman su información porque sus probabilidades se multiplican.

2 Logaritmos

Qué se debe saber.

$$\log_b x = y \Leftrightarrow b^y = x \tag{3}$$

Parte	Qué significa
b	la **base** ($b > 0$, $b \neq 1$); en el curso casi siempre $b = 2$
x	el número del que se toma el logaritmo ($x > 0$)
y	el exponente al que hay que elevar b para obtener x

Propiedades que se usan todo el tiempo:

$$\log_b(xy) = \log_b x + \log_b y, \qquad \log_b \frac{x}{y} = \log_b x - \log_b y, \qquad \log_b x^k = k \log_b x \tag{4}$$

$$\log_2 x = \frac{\ln x}{\ln 2} \tag{5}$$

Parte	Qué significa
$\ln x$	logaritmo natural (base $e \approx 2.718$), el que traen las calculadoras
$\ln 2 \approx 0.6931$	constante que convierte de base e a base 2

Ejercicio resuelto. Calcular $\log_2 64$, $\log_2 \frac{1}{8}$ y $\log_2 10$.

1. $64 = 2^6$, así que por la Ecuación 3, $\log_2 64 = 6$.
2. $\frac{1}{8} = 2^{-3}$, así que $\log_2 \frac{1}{8} = -3$.
3. 10 no es potencia de 2; con la Ecuación 5: $\log_2 10 = \frac{\ln 10}{\ln 2} = \frac{2.3026}{0.6931} \approx 3.32$. Comprobación: $2^3 = 8 < 10 < 16 = 2^4$, así que el resultado debe estar entre 3 y 4. ✓

Conexión con el curso: toda medida de información es un logaritmo; la base 2 da la unidad **bit**.

3 Variables aleatorias discretas y valor esperado

Qué se debe saber. Una variable aleatoria discreta X toma valores x con probabilidades $p(x)$, que son no negativas y suman 1.

$$E[X] = \sum_x x\, p(x) \tag{6}$$

$$E[g(X)] = \sum_x g(x)\, p(x) \tag{7}$$

Parte	Qué significa
$E[\cdot]$	**valor esperado**: promedio ponderado por las probabilidades
x, $p(x)$	cada valor posible y su probabilidad
g	cualquier función de X (por ejemplo x^2, o $-\log_2 p(x)$)

Ejercicio resuelto. X toma los valores $1, 2, 3$ con probabilidades $\frac{1}{2}, \frac{1}{4}, \frac{1}{4}$. Calcular $E[X]$ y $E[X^2]$.

1. Por la Ecuación 6: $E[X] = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{4} = 0.5 + 0.5 + 0.75 = 1.75$.
2. Por la Ecuación 7 con $g(x) = x^2$: $E[X^2] = 1 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} + 9 \cdot \frac{1}{4} = 0.5 + 1 + 2.25 = 3.75$.
3. Observación: $E[X^2] = 3.75 \neq E[X]^2 = 3.0625$. En general $E[g(X)] \neq g(E[X])$; la diferencia entre ambos lados es el tema de la desigualdad de Jensen.

Conexión con el curso: la **entropía** es el valor esperado del contenido de información, $H(X) = E[-\log_2 p(X)]$, es decir, la Ecuación 7 con $g(x) = -\log_2 p(x)$.

4 Distribuciones conjuntas, marginales y condicionales

Qué se debe saber. Para dos variables X y Y, la **distribución conjunta** $p(x, y)$ da la probabilidad de que $X = x$ **y** $Y = y$ al mismo tiempo.

$$p(x) = \sum_{y} p(x, y), \qquad p(y) = \sum_{x} p(x, y) \tag{8}$$

$$p(x \mid y) = \frac{p(x, y)}{p(y)} \tag{9}$$

$$X \text{ y } Y \text{ son independientes} \Leftrightarrow p(x, y) = p(x)\, p(y) \text{ para todo } x, y \tag{10}$$

Parte	Qué significa
$p(x), p(y)$	distribuciones **marginales**: se suman los renglones o las columnas de la tabla conjunta
$p(x \mid y)$	probabilidad **condicional** de x sabiendo que ocurrió y
independencia	la conjunta es el producto de las marginales en **todas** las celdas

Ejercicio resuelto. Con la tabla siguiente, ¿son X y Y independientes? Calcular $P(X = 1 \mid Y = 1)$.

	$Y = 0$	$Y = 1$
$X = 0$	0.3	0.2
$X = 1$	0.1	0.4

1. Marginales (Ecuación 8): $P(X = 0) = 0.3 + 0.2 = 0.5$, $P(X = 1) = 0.5$, $P(Y = 0) = 0.3 + 0.1 = 0.4$, $P(Y = 1) = 0.6$.
2. Independencia (Ecuación 10): basta una celda que falle. $P(X = 0)\, P(Y = 0) = 0.5 \cdot 0.4 = 0.2$, pero $p(0, 0) = 0.3$. Como $0.2 \neq 0.3$, **no son independientes**.
3. Condicional (Ecuación 9): $P(X = 1 \mid Y = 1) = \frac{p(1,1)}{P(Y=1)} = \frac{0.4}{0.6} = \frac{2}{3}$.

Conexión con el curso: entropía conjunta, entropía condicional e información mutua se calculan a partir de estas tres operaciones.

5 Funciones convexas

Qué se debe saber. Una función f es **convexa** en un intervalo si la cuerda entre dos puntos de su gráfica queda por encima de la gráfica:

$$f(\lambda a + (1 - \lambda) b) \leq \lambda f(a) + (1 - \lambda) f(b) \quad \text{para} \quad \lambda \in [0, 1] \tag{11}$$

Parte	Qué significa
a, b	dos puntos cualesquiera del intervalo
λ	peso entre 0 y 1; $\lambda a + (1-\lambda)b$ recorre el segmento entre a y b
lado izquierdo	la función evaluada en el punto intermedio
lado derecho	el punto correspondiente sobre la cuerda

Criterio práctico: si $f''(x) \geq 0$ en el intervalo, f es convexa.

Ejercicio resuelto. ¿Es $f(x) = x \ln x$ convexa en $(0, \infty)$?

1. Primera derivada (regla del producto): $f'(x) = \ln x + x \cdot \frac{1}{x} = \ln x + 1$.
2. Segunda derivada: $f''(x) = \frac{1}{x}$.
3. Para $x > 0$, $\frac{1}{x} > 0$; por el criterio, f es **convexa**. Con $\log_2$ en lugar de ln sólo cambia una constante positiva: $f''(x) = \frac{1}{x \ln 2} > 0$.

Conexión con el curso: la desigualdad de Jensen, $E[f(X)] \geq f(E[X])$ para f convexa, es la herramienta con la que se demuestran casi todas las propiedades de la entropía.

6 Cadenas de Markov

Qué se debe saber. Una cadena de Markov pasa de un estado a otro con probabilidades que sólo dependen del estado actual.

$$P_{ij} = P(X_{n+1} = j \mid X_n = i) \tag{12}$$

$$\pi P = \pi, \qquad \sum_i \pi_i = 1 \tag{13}$$

Parte	Qué significa
X_n	estado de la cadena en el paso n
P_{ij}	probabilidad de pasar del estado i al j; cada **renglón** de la matriz P suma 1
π	**distribución estacionaria**: vector renglón de probabilidades que no cambia al dar un paso

Ejercicio resuelto. Encontrar la distribución estacionaria de $P = \begin{pmatrix} 0.9 & 0.1 \\ 0.5 & 0.5 \end{pmatrix}$.

1. Se escribe $\pi = (\pi_1, \pi_2)$. La primera componente de $\pi P = \pi$ (Ecuación 13) da $0.9\,\pi_1 + 0.5\,\pi_2 = \pi_1$.
2. Despejando: $0.5\,\pi_2 = 0.1\,\pi_1$, es decir, $\pi_1 = 5\,\pi_2$.
3. Con $\pi_1 + \pi_2 = 1$: $5\pi_2 + \pi_2 = 1 \Rightarrow \pi_2 = \frac{1}{6},\ \pi_1 = \frac{5}{6}$.
4. Comprobación: $\frac{5}{6} \cdot 0.9 + \frac{1}{6} \cdot 0.5 = 0.75 + 0.0833 = 0.8333 = \frac{5}{6}$. ✓

Conexión con el curso: una fuente con memoria (como un idioma, donde cada letra depende de la anterior) se modela con una cadena de Markov; su *tasa de entropía* usa la distribución estacionaria.

7 Búsqueda binaria y $\log_2 n$

Qué se debe saber. Cada pregunta de sí/no, bien elegida, parte el conjunto de candidatos a la mitad. Con k preguntas se distinguen hasta 2^k opciones, así que para n opciones hacen falta

$$k = \lceil \log_2 n \rceil \tag{14}$$

Parte	Qué significa
n	número de opciones posibles
k	número de preguntas de sí/no en el peor caso
$\lceil \cdot \rceil$	redondear hacia arriba al entero más cercano

Ejercicio resuelto. ¿Cuántas preguntas de sí/no se necesitan, en el peor caso, para adivinar un entero del 1 al 100?

1. Se busca el menor k con $2^k \geq 100$.
2. $2^6 = 64 < 100$ (no alcanza) y $2^7 = 128 \geq 100$ (sí alcanza).
3. Por la Ecuación 14: $k = \lceil \log_2 100 \rceil = \lceil 6.64 \rceil = 7$ preguntas. Estrategia: "¿es mayor que 50?", luego "¿mayor que 75?", etc.

Conexión con el curso: el número de preguntas de sí/no es el número de **bits**. Cuando las opciones no son igual de probables, conviene preguntar primero por las más probables, y el número promedio de preguntas baja hasta la **entropía**.

8 ¿Qué es "información"?

En el lenguaje cotidiano, *información* suele asociarse con **significado**: una noticia importante, un dato útil. Shannon (1948) propuso algo distinto y medible: la información es **reducción de incertidumbre**, y depende sólo de qué tan probable era lo que se observó, no de lo que significa.

- "Mañana sale el sol en Mexicali" casi no informa: era casi seguro.
- "Mañana nieva en Mérida" informa mucho: era muy improbable.

Esa idea, convertida en fórmula, es el **contenido de información** $-\log_2 p$ (también llamado *sorpresa*) y su promedio, la **entropía**, con las que arranca el curso.